

گزارش پروژه پایانی پردازش تصویر

پاسخ به سؤالات تحلیلی پروژه

نام و نام خانوادگی: حامد پوراغنیایی شماره دانشجویی: 402222031

1. تحلیل پیش پردازش

سؤال: اگر در فاز اول خط $\text{input_tensor} = \text{image.astype}(\text{np.float32}) / 255.0$ را حذف می کردیم، چه اتفاقی برای پیش بینی مدل می افتاد و چرا؟

پاسخ: در این حالت مقدار پیکسل ها به جای بازه 0 تا 1، در بازه 0 تا 255 باقی می ماند. مدل حذف نویز با داده های نرمال شده آموزش دیده است، بنابراین این مقادیر بزرگ با ورودی مورد انتظار مدل فرق دارند. ممکن است فعال سازی های شبکه بیش از حد بزرگ یا اشباع شوند و تصویر خروجی رنگ های اشتباه، آرتیفکت زیاد یا حذف نویز ضعیفی داشته باشد. نرمال سازی باعث می شود محاسبات مدل پایدار بماند.

2. تحلیل معماری رفع تاری

سؤال: چرا شبکه ای مانند ResNet با اتصال های میان بر می تواند لبه ها را بهتر از یک شبکه ی ساده و بدون اتصال میان بر بازیابی کند؟

پاسخ: اتصال های میان بر یک مسیر کوتاه برای انتقال اطلاعات مفید تصویر از لایه های اولیه به لایه های بعدی ایجاد می کنند. در نتیجه، لایه های عمیق تر می توانند جزئیات از دست رفته را یاد بگیرند، بدون اینکه لبه ها و ساختار اصلی تصویر کاملاً از بین برود. این اتصال ها عبور گرادیان در شبکه را نیز آسان تر می کنند. در نتایج من، PSNR مدل ResNet برابر 18.95 dB بود. مقدار PSNR برای CNN برابر 18.94 dB و برای U-Net برابر 18.77 dB بود. اختلاف کم بود، اما ResNet بهترین مدل بین این سه معماری بود.

3. تحلیل نمودارهای یادگیری

سؤال: با توجه به نمودارهای Loss فاز سوم، آیا مدل دچار بیش برآزش شده است یا آموزش درستی داشته است؟

پاسخ: مدل آموزش مناسبی داشته است. خطای آموزش از 1.7029 در دوره ی اول به حدود 0.5103 در دوره ی آخر کاهش پیدا کرد. خطای تست نیز از 1.6268 به حدود 0.6511 رسید. هر دو نمودار به طور کلی با هم کاهش پیدا کردند و خطای تست بعد از مدتی شروع به افزایش مداوم نکرد. پس مدل فقط داده های آموزش را حفظ نکرده و ویژگی های مفیدی یاد گرفته است. دقت نهایی مدل روی داده ی تست تمیز CIFAR-10 نیز 93.99% بود که این نتیجه را تأیید می کند.

4. درک معیارهای Accuracy و F1-Score

سؤال: یک مثال واقعی، به جز تشخیص سرطان، بیان کنید که در آن نامتعادل بودن داده باعث گمراه کننده بودن Accuracy می شود و باید از F1-Score استفاده کنیم.

پاسخ: فیلتر تشخیص ایمیل اسپم یک مثال مناسب است. فرض می کنیم مجموعه داده شامل 990 ایمیل عادی و فقط 10 ایمیل اسپم باشد. اگر مدل همه ی ایمیل ها را عادی تشخیص دهد، دقت آن 99% می شود، اما هیچ ایمیل اسپمی را پیدا نکرده است. در این حالت F1-Score کلاس اسپم بسیار پایین خواهد بود، چون Recall آن صفر است. F1-Score برای این مسئله بهتر است، چون Precision و Recall کلاس کم تعداد را با هم بررسی می کند.

5. تحلیل ماتریس درهم ریختگی

سؤال: کدام دو کلاس بیشتر از همه با یکدیگر اشتباه گرفته شدند و چرا شبکه ممکن است این دو کلاس را اشتباه تشخیص دهد؟

پاسخ: بیشترین خطای خارج از قطر اصلی بین کلاس های گربه و سگ بود. مدل 66 تصویر گربه را سگ تشخیص داد و 65 تصویر سگ را گربه پیش بینی کرد. این دو کلاس ویژگی های مشترک زیادی دارند؛ مانند مو، چهار پا، شکل نسبتاً مشابه صورت و بدن و

پس‌زمینه‌های خانگی یا طبیعی. تصاویر CIFAR-10 فقط 32 در 32 پیکسل هستند، بنابراین جزئیاتی مثل شکل گوش، بینی و صورت به‌خوبی دیده نمی‌شوند. وضوح پایین و بافت‌های مشابه باعث می‌شود CNN گاهی گربه و سگ را با هم اشتباه بگیرد.

نتیجه‌ی نهایی خط لوله: تصویر بازیابی‌شده با اطمینان 91.94% به‌درستی در کلاس پرنده قرار گرفت.